

POLITECHNIKA WROCŁAWSKA
WYDZIAŁ ELEKTRONIKI

Katedra Cybernetyki i Robotyki

RAPORT serii SPR-16 / 2014

Algorytmy akwizycji i analizy biosygnalów

AUTORZY:

Andrzej Wołczowski, Robert Wójcik,
Maciej Przydatek, Delia Gonzales Guzman,
Bartosz Maciurak, Damian Barański

Słowa kluczowe:

- biosterowanie
- analiza sygnałów EMG
- ekstrakcja cech
- selekcja cech

Badania finansowane ze środków statutowych

WROCŁAW 2014-12-11

Algorytmy akwizycji i analizy biosygnalów

1. WSTĘP

Niektóre procesy/zjawiska w organizmie ludzkim są zależne od woli człowieka. Towarzyszące im sygnały (biosygnaly) można wykorzystać do sterowania maszyną. To wymaga rozpoznania intencji człowieka na drodze klasyfikacji biosygnalów.

Dla uzyskania niezawodnego sterowania wieloma, (często powiązanymi wzajemnie) parametrami procesu, liczba rozpoznawanych klas powinna być duża, a błąd ich rozpoznawania marginalny.

Niestety, z reguły, wraz z liczbą rozpoznawanych klas rośnie dość szybko błąd rozpoznawania. Dzieje się tak m.in. dlatego, że zawarta w rejestrowanym sygnale informacja o intencji człowieka jest na ogół silnie zniekształcona przez zakłócenia, a postać w jakiej występuje w sygnale obciąża dodatkowo proces klasyfikacji (pogarsza skuteczność, niezawodność).

Dlatego niezbędnym etapem rozpoznawania, poprzedzającym proces klasyfikacji, jest proces analizy biosygnalów prowadzący do zastąpienia pierwotnej postaci sygnału - wektorem reprezentujących go cech. Właściwa transformacja sygnału na wektor cech pozwala na istotne zredukowanie zakłóceń (występujących w sygnale pierwotnym), a także na redukcję wymiarowości obiektu rozpoznawania i dopasowanie jej do przyjętego klasyfikatora.

W rozważanym tu ujęciu analiza sygnału polega na określeniu takiego zestawu opisujących go cech aby zachować zawartą w nim informację o intencji (decyzji sterującej) człowieka. Tą część analizy określamy mianem ekstrakcji cech. Do ekstrakcji wykorzystywane są metody, które transformują sygnał (na ogół zarejestrowany w postaci dyskretnej - ciągu uporządkowanych w czasie próbek) na zestaw określonych parametrów. Większość tych metod wytwarza nadmiarowe zestawy cech. Dla podniesienia efektywności klasyfikacji należy przeprowadzić drugą część analizy – dobór optymalnego zestawu cech (optymalnego w sensie min liczby cech zapewniającej klasyfikację z przyjętą dopuszczalną wartością błędu), który jest realizowany na drodze selekcji lub redukcji zestawu pierwotnego cech.

Istnieje wiele metod ekstrakcji i selekcji cech. Wdaje się oczywiste, że pewne z nich – ze względu na własności biosygnalów i charakter zawartej w nich informacji - mogą prowadzić do uzyskania lepszych zestawów cech w sensie efektywności (niezawodności, szybkości i kosztów obliczeniowych) ich rozpoznawania. Dlatego została podjęta praca zmierzająca do potwierdzenia tej tezy i wyłonienia metod ekstrakcji oraz selekcji/redukcji zapewniających dobrą (w sensie: efektywną) analizę takich biosygnalów jak sygnały EMG.

2. GENEZA I KONCEPCJA BADAŃ

Dla realizacji postawionego celu przyjęto drogę eksperymentalną. Badania przeprowadzono na sygnałach EMG mających swoje źródło w mięśniach przedramienia i towarzyszących ruchom palców dłoni. Takie sygnały są wytwarzane przez mięśnie kikutu ręki, również po amputacji części kończyny górnej wraz z dłonią, mogą więc być wykorzystane do sterowania protezą dłoni. Aby taka proteza dobrze odtwarzała utracone funkcje manipulacyjno/chwytne dłoni, jej konstrukcja mechaniczna powinna być wieloprzegubowa, a jej sterowanie powinno umożliwiać różnorodne ruchy przegubów prowadzące do różnych ruchów i postur palców. Ponadto sterowanie to musi być niezawodne, ponieważ proteza nie może wykonywać niechcianych ruchów.

Taka proteza stanowi więc dobry przykład systemu sterowania, opartego na rozpoznawaniu biosygnalów, w którym liczba rozpoznawanych klas powinna być duża, a błąd ich rozpoznawania mały. Z drugiej strony biosygnaly mierzone na kikucie przedramienia metoda nieinwazyjną, na powierzchni skóry, są (niestety) dobrym przykładem sygnałów silnie zakłóconych, których

niezawodne rozpoznawanie jest problemem trudnym. Dobór właściwych metod analizy takich sygnałów jest zadaniem nie trywialnym.

Jak zostało przedstawione we wprowadzeniu, rozpoznawanie sygnałów obejmuje dwie zasadnicze fazy:

- 1) reprezentację sygnału za pomocą charakteryzujących go cech (analiza sygnału),
- 2) a następnie klasyfikację.

Obydwie fazy mają wpływ na błąd rozpoznawania. Trafny dobór cech na etapie syntezy procesu rozpoznawania umożliwia efektywną realizację całości (zwiększa szybkość i redukuje zasoby).

Jeden ze sposobów badania efektywności metod analizy prowadzi przez eksperymentalne porównanie końcowych błędów rozpoznawania różnych wektorów cech, przygotowanych różnymi metodami. Dlatego zajmujemy się również klasyfikacją – ale tylko jako narzędziem do testowania metod selekcji.


Przy takim podejściu istotnego znaczenia nabiera etap akwizycji biosygnali. Pierwszy rozdział omawia metodologię pomiaru: dobór badanych ruchów, stanowisko pomiarowe i sposób rozmieszczenia elektrod pomiarowych na badanej kończynie oraz sam przebieg procesu rejestracji biosygnali. Wynikiem tego etapu badań jest baza danych tekstowych zawierająca zapis sygnałów EMG towarzyszących wybranym typom ruchów dłoni (9 ruchów, 50 powtórzeń na każdy ruch) w wykonaniu 4-rech osób. Kolejne rozdziały omawiają ekstrakcję cech opartą na transformacji sygnałów z dziedziny czasu w dziedzinę częstotliwości (dyskretna DFT i krótkoczasową transformata Fouriera STFT) oraz badanie wpływu redukcji wymiarowości wektora cech na efekty rozpoznawania. Zaproponowano własną miarę dyskryminacji cech nawiązującą do koncepcji podanej przez Fishera [1] i porównano jej efektywność z metodą PCA [2]. Do klasyfikacji użyto algorytmu kNN.

3. METODOLOGIA POMIARU BIOSYGNAŁÓW

Do rejestracji sygnałów EMG wykorzystano 8 kanałowy układ pomiarowy opisany w [9]. Oznacza to, że dla każdego rodzaju (klasy) ruchu (przykładowo: chwyt za długopis stojący w kubeczku) są rejestrowane równocześnie przebiegi EMG z 8 kanałów karty pomiarowej, dostarczane z 8 elektrod E_i ($i=1, 2, \dots, 8$) rozmieszczonych w ustalonych miejscach przedramienia.

Przyjęty sposób rozmieszczenia elektrod pokazuje rys 1. Po stronie wewnętrznej przedramienia (rys 1A) elektrody zostały rozmieszczone równomiernie na linii biegnącej od podstawy kciuka do łokcia, a po stronie zewnętrznej (rys 1B) na linii biegnącej od podstawy małego palca do łokcia.

Próbkowanie sygnału w każdym kanale karty pomiarowej odbywa się z częstotliwością $f = 1\text{kHz}$ (okres próbkowania $T_f = 1\text{ms}$). Sterownik karty buforuje w pamięci wewnętrznej karty 15 kolejnych próbek dla każdego z 8 kanałów i zapisuje je do pliku tekstowego. Podczas inicjowania sterownika karty (przez program użytkownika), podawane są m.in.: adres bufora (w programie użytkownika) do którego sterownik ma przepisać zadaną liczbę próbek z karty, oraz adres procedury wywoływanej po zakończeniu przepisywania, która przepisuje dane z bufora do pliku tekstowego (w naszym przypadku jest to 8 ciągów próbek po 15 wartości). Oznacza to zapis kolejnej porcji danych do pliku tekstowego, co 15ms.



Rys. 1. Rozmieszczenie elektrod na przedramieniu

Poniżej pokazano organizację pliku tekstowego i przykładowe dane zebrane z 8 kanałów, podczas pojedynczego pomiaru, trwającego ok. 2s.

Tabela 1. Plik tekstowy zawierający przykładowe dane dla ruchu 1, powtórzenie 14, kanał 1.

1sze 15cie próbek								
	Kanał 1	Kanał 2	Kanał 3	Kanał 4	Kanał 5	Kanał 6	Kanał 7	Kanał 8
1	0.0610928	0.0711526	-0.0143496	-0.0356958	-0.00693361	-0.0059440	-0.00324781	-0.038103
2	0.0371504	0.0256892	-0.0087961	-0.033927	0.0109556	-0.0356297	0.0100458	-0.025100
.	0.0107357	-0.0938588	-0.0058490	-0.0277078	0.00580128	0.0610098	-0.00035905	0.0151005
.	-0.0361548	-0.0537461	-0.0078822	-0.0081154	-0.0103777	-0.0552837	-0.0125339	-0.068973
.	-0.0605399	0.0402595	-0.0066558	0.0281117	-0.00962282	-0.171823	-0.0189489	-0.157847
.	-0.0478002	0.0972413	0.00525781	0.00378921	-0.00713518	0.00639116	-0.00145383	-0.045683
.	-0.165416	0.0751963	-0.0311144	-0.0222324	-0.00312642	0.0338688	0.00506698	-0.053393
.	0.0868313	-0.0214885	-0.0083159	-0.0059598	-0.00536366	0.0669645	0.00191869	-0.035844
.	0.0479541	0.0377487	-0.0078357	-0.0311036	-0.00011797	-0.0138418	0.00651955	-0.013468
.	0.0646581	0.0131611	0.00114631	0.0107948	-0.00067884	-0.0497032	-0.00304498	-0.026664
.	-0.0606925	0.0503406	-0.0211836	-0.0022804	-0.00319527	-0.0461123	-0.00886659	0.0344509
13	0.00316246	-0.0050150	-0.0151319	0.0483499	-0.00187321	-0.018911	-0.00036031	-0.095701
14	-0.0368425	0.00264856	-0.0289741	0.0224726	-0.00156523	0.0341991	-0.00508085	-0.055321
15	-0.0635355	0.0206269	0.0177369	-0.0190726	-0.00573048	0.0335183	0.000801235	-0.071237
kolejne 15 cie próbek								
16	0.0110821	0.0256445	0.0181848	-0.0075391	-0.00785381	-0.070043	-0.00093100	-0.159539
17	-0.0167977	0.0242762	-0.031898	0.0342161	-0.0061499	-0.0701334	-0.00781968	-0.016594
.	-0.0453164	0.0127808	-0.0156198	-0.0068765	-0.00402908	-0.0043451	-0.0053265	0.0234848
.	-0.0130207	-0.0041355	0.00090362	-0.0216781	-0.00407665	0.0223675	0.00823163	-0.063361
.	-0.0035627	0.0236009	0.0188432	0.0312754	-0.00898181	0.016556	-0.00678286	-0.130333
.	-0.0473293	-0.0049716	0.00296389	0.00490568	-0.00216367	0.011733	0.00685466	-0.014706
.	0.0311064	0.0272055	-0.0338898	0.0344147	-0.00062250	0.0220824	0.00446605	-0.066252
.	0.0156379	-0.0074006	-0.0028967	0.0110707	-0.00761969	0.00463275	-0.00591988	-0.081149
.	0.0035512	0.028639	0.0118104	0.0027372	-0.00762344	-0.0500059	-0.00813464	-0.138001
.	-0.034097	-0.0023537	0.00014973	-0.0131473	-0.00665569	-0.127835	-0.00601059	-0.167882
.	0.0115825	0.0217527	-0.0342513	-0.0175719	-0.00521093	-0.0006562	-0.00084281	-0.092266
.	0.0311487	0.0096178	0.00683657	0.0513731	-0.00536116	0.0489722	0.00659513	0.0189801
.	0.0101994	0.0366472	0.00762273	0.0526752	-0.0047452	0.0656833	0.00094234	-0.086727
29	-0.0358957	-0.0030531	-0.0055005	-0.0117137	-0.00594833	0.0199962	0.00658253	-0.007870

133 porcja kolejnych 15tu próbek								
1981	-0.0557006	0.0302638	-0.0102897	-0.0185556	-0.0122031	-0.0533168	-0.00471298	-0.021836
.	0.00148566	0.0288623	-0.0069140	0.0330236	-0.0141086	-0.0195466	-0.00595516	-0.097949
.	0.0204566	0.0308101	0.00630472	-0.0054158	-0.00553268	-0.0071975	-0.00045480	-0.021078
.	-0.0323406	0.0224139	0.0158096	0.00071699	-0.00220248	0.0246635	0.000634938	-0.042473
.	-0.0062082	-0.0431186	-0.0106602	0.0272414	0.00301818	-0.0427726	-0.00495864	-0.171705
.	-0.0071652	0.0221241	0.00096171	0.010185	0.00448423	-0.0124225	0.00215806	-0.161969
.	0.00105971	0.0234746	-0.0157941	0.019109	-0.0131095	-0.0112055	0.000859192	0.0230555
.	-0.0204246	0.00307871	-0.0167377	0.0357877	-0.00952641	0.0174603	0.00328812	-0.008607
.	0.0298645	0.0104207	-0.0198656	0.046456	-0.00617368	-0.0017088	0.000997772	-0.132698
.	-0.0434638	0.0379236	0.00872773	-0.0404736	-0.00800153	0.00307405	-0.00215933	-0.141184
.	-0.0437306	-0.0421792	0.00088167	-0.0243687	-0.00729543	-0.0133356	-0.00409819	-0.161248
.	0.0346845	0.0196364	0.00894977	0.0131541	-0.00183315	-0.0086369	-0.00052786	-0.042303
1994	-0.0446313	0.0353044	-0.0205175	-0.0034033	-0.00641907	0.00614247	-0.00454038	-0.052537
1995	-0.0507753	0.0140585	-0.0234065	0.0081081	-0.00429073	-0.0161591	0.000298573	0.0044858


Czas trwania jednego pomiaru (dla każdego powtórzenia, dla każdego badanego ruchu) ustalono na ok. 2s (dokładnie 1995ms = 15ms x 133, co wynika z przyjętej wielokrotności (133) okresu (15) przepisywania próbek). W tym czasie osoba badana wykonuje 1-no powtórzenie badanego ruchu, które obejmuje:

- a) przygotowanie chwytu (wyciągnięcie przedramienia w kierunku chwytanego przedmiotu i ułożenie palców do chwytu);
- b) oraz sam chwyt (zaciśnięcie palców na przedmiocie i uniesienie przedmiotu).

Odłożenie chwyconego przedmiotu jest realizowane w fazie „odpoczynku”.

Rozpoczęcie każdego powtórzenia pomiaru jest oznaczone sygnałem dźwiękowym oraz zielonym paskiem postępu na ekranie.

Koniec paska postępu oznacza zakończenie rejestracji ruchu. Osoba badana odkłada uchwycony przedmiot i przygotowuje się do kolejnego, w tym czasie osoba asystująca akceptuje wykonany pomiar (przez naciśnięcie dowolnego klawisza) lub nie akceptuje pomiaru naciskając Esc. Akceptacja uruchamia czerwony pasek przerwy. Przerwa trwa 3s. Wynik zaakceptowanego pomiaru jest zapisywany w odpowiednim katalogu w pliku tekstowym (vide Tab. 1.). Jeżeli wykonanie powtórzenia ruchu nie zostało zaakceptowane – wynik nie jest zapisywany, uaktywnia się ponownie pasek przerwy (aby osoba badana mogła się „pozbierać”), a potem ruch i jego pomiar są powtarzane ponownie.



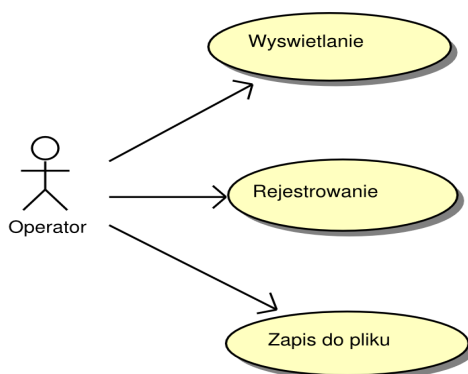
Rys. 2. Główne okno programu EMG_Rejestrator

Dla każdego powtórzenia ruchu otrzymujemy zapis w postaci 8-miu wektorów, o 1995 współrzędnych każdy, które reprezentują dyskretne wartości amplitudy sygnału EMG, powstającego podczas wykonywania ruchu, zebrane w ciągu 1995 ms, z okresem próbkowania 1kHz, niezależnie z 8 kanałów.

Należy zauważyć, że już na etapie wykonywania pomiarów eliminujemy te pomiary, które w istotny sposób różnią się od pozostałych - zapisując tylko poprawne dane. Oceny dokonuje prowadzący eksperyment, obserwując wykonanie ruchu oraz postać graficzną przebiegu czasowego sygnału, akceptując (naciśnięcie dowolnego klawisza) lub odrzucając (naciśnięcie Esc) pomiar.

Do rejestracji biosygnalów opracowano program EMG_Rejestrator [10] (vide rys. 2 i 3), którego działanie opiera się na oczekiwaniu na decyzje operatora i w zależności od tych decyzji wykonywaniu następujących operacji:

- rejestrowanie i buforowanie pomiarów w pamięci,
- wyświetlanie przebiegów czasowych na ekranie monitora w czasie rzeczywistym;
- wyświetlanie informacji o stanie pomiarów (faza rejestracji przebiegu, faza odpoczynku);
- zapis danych do pliku tekstowego na dysku;
- modyfikacja parametrów pomiarów.



Rys. 3. Funkcjonalności programu EMG_Rejestrator

Przed kontynuacją dalszych pomiarów badanego ruchu, dane z dotychczasowych pomiarów można poddać wstępnej analizie w celu wizualizacji sygnałów oraz ich cech. Pozwala to śledzić i utrzymać poprawny przebieg procesu rejestracji (przyleganie elektrod i elektrody odniesienia, korekta wzmocnień kanałów, obserwacja poziomu zakłóceń zewnętrznych i zmęczenia osoby badanej). Opracowany program pozwala na obserwację przebiegu procesu rejestracji w zakresie:

- uśrednionego przebiegu czasowego (filtr okienkowy Gaussa) - przekształcenie P1;
- spektrum częstotliwościowego z dyskretnej transformaty Fouriera (DFT) - przekształcenie P2;
- spektrum częstotliwościowego uśrednionego (filtr Gaussa dla DFT) - przekształcenie P3;
- spektrogramu 2D (krótco-czasowa transformata Fouriera, STFT, zobrazowana na płaszczyźnie - rozkład energii w dziedzinie czasu i częstotliwości) - przekształcenie P4;
- spektrogramu 3D (transformata STFT zobrazowana w układzie przestrzennym - rozkład energii w dziedzinie czasu i częstotliwości) - P4a;
- spektrogramu słupkowego 3D (rozkład energii w dziedzinie czasu i częstotliwości wyznaczony w pewnych przedziałach czasowych i częstotliwościowych wynikających z podanych parametrów transformaty STFT; w naszym przypadku - 65 przedziałów częstotliwościowych oraz 20 przedziałów czasowych) - P4b.

Każda z przedstawionych transformacji może być użyta także w procesie rozpoznawania sygnałów. W niniejszej pracy do ekstrakcji cech została wykorzystana głównie metoda transformaty STFT.

4. ORGANIZACJA BAZY DANYCH

Baza danych zawiera katalogi odpowiadające badanym osobom. W każdym katalogu znajdują się podkatalogi związane z kolejnymi typami badanych ruchów:

1_długopis, 2_śróbka, 3_potencjometr, 4_szkłanka, 5_kubek, 6_czjnik, 7_karta, 8_komórka, 9_myszka.

Każdy podkatalog „i_ruch”, zawiera pliki tekstowe (powt_01, powt_02, ... , powt_R), odpowiadające kolejnym powtórzeniom pomiaru dla danego typu ruchu. Każdy plik tekstowy „powt_r”, zawiera dane liczbowe zorganizowane w postaci macierzy o 1995 wierszach i 8 kolumnach. Kolumny zawierają próbki sygnału zmierzone w kolejnych chwilach czasu w przedziale od 0 do 1995ms, w odrębnych kanałach.

Dane z pojedynczej kolumny pliku tekstowego „powt_r”, można przedstawić wektorem:

$$\overline{w}_k^{i,r} = [w_k^{i,r}(t_1), w_k^{i,r}(t_2), \dots, w_k^{i,r}(t_{1995})], \quad (1)$$

gdzie: i – numer typu ruchu (i=1,...,9); r – numer powtórzenia ruchu (r=1,...,50), k – numer kolumny (=numer kanału; k=1,...,8), tj – chwila pomiaru próbki (liczona w danym powtórzeniu), j=1, 2, ..., 1995.

W ten sposób r-te powtórzenie i-tego ruchu można przedstawić w postaci macierzy $W^{i,r}$:

$$W^{i,r} = \begin{bmatrix} w_1^{i,r}(t_1) & w_2^{i,r}(t_1) & \dots & \dots & w_8^{i,r}(t_1) \\ w_1^{i,r}(t_2) & w_2^{i,r}(t_2) & & & w_8^{i,r}(t_2) \\ \dots & \dots & \dots & & \dots \\ \dots & \dots & \dots & \dots & \dots \\ w_1^{i,r}(t_{1995}) & w_2^{i,r}(t_{1995}) & \dots & \dots & w_8^{i,r}(t_{1995}) \end{bmatrix} \quad (2)$$

Konkatenując wektory $\overline{w}_k^{i,r}$ dla kolejnych kolumn, od k = 1 do 8, otrzymamy wektor:

$$\langle w^{i,r} \rangle = [\overline{w}_1^{i,r}, \overline{w}_2^{i,r}, \dots, \overline{w}_8^{i,r}] = [d_1^{i,r}, d_2^{i,r}, \dots, d_{15960}^{i,r}], \quad d_m^{i,r} = w_k^{i,r}(t_j), \quad (3)$$

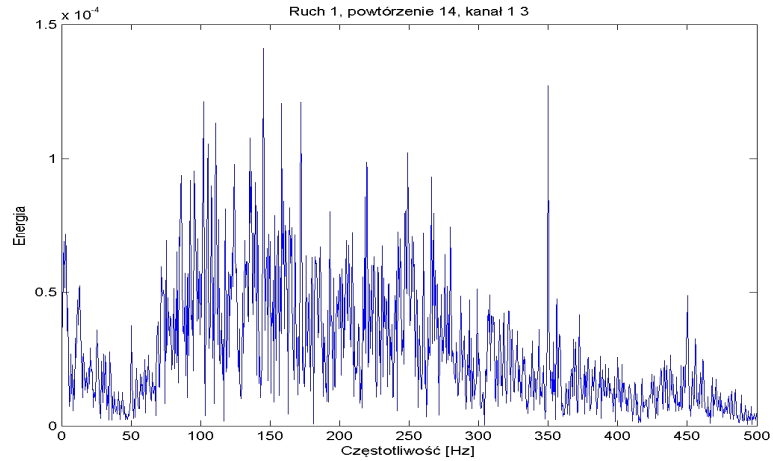
gdzie: $m = (k - 1)1995 + j$,

reprezentujący dane liczbowe $d_m^{i,r}$, $m \in [1, \dots, 8 \times 1995 = 15960]$ z pliku „powt_r”, z katalogu „i_ruch”.

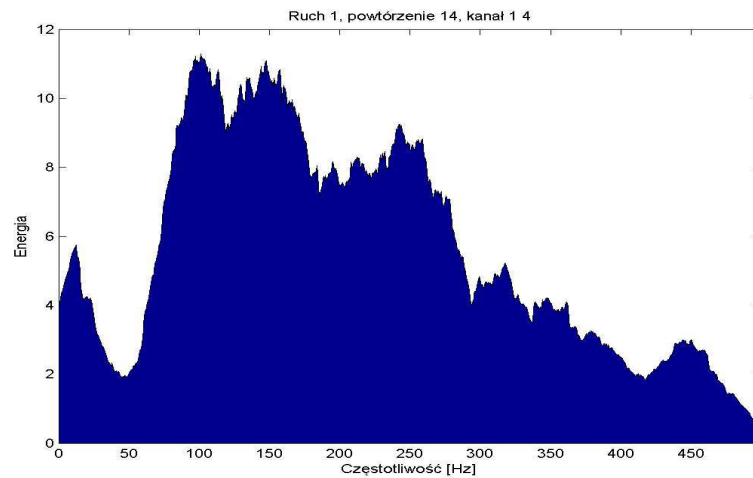
Pomiar sygnału dla każdego typu ruchu powtarzamy R - krotnie (wstępnie przyjęto R = 50 [docelowo R = 200]).

5. WTÓRNA BAZA DANYCH (DFT)

Dla każdego zarejestrowanego sygnału (9 klas ruchu x 50 powtórzeń), z pojedynczego kanału, wyznaczamy dyskretne spektrum za pomocą DFT (rys. 4). Filtrujemy spektrum przez uśrednianie jego sąsiednich amplitud (rys. 5).



Rys. 4. Przykładowe spektrum dla ruchu 1 (powtórzenie 14, kanał 1, typ wykresu 3)



Rys. 5. Spektrum filtrowane dla ruchu 1 (powtórzenie 14, kanał 1, typ wykresu 4)

Uśrednione spektrum zapisujemy w postaci wektora, którego współrzędne są amplitudami kolejnych składowych częstotliwości. Dla każdego ruchu-powtórzenia konkatenujemy 8 wektorów (z 8 kanałów), otrzymując ‘pełny’ wektor DFT ($\bar{f}s^{i,r}$).

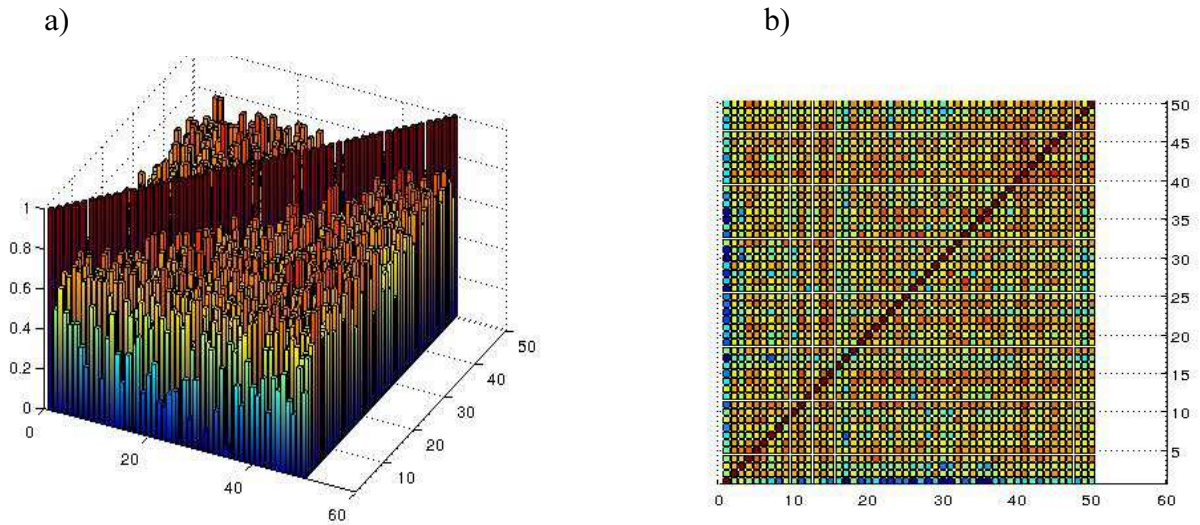
Dla każdej klasy ruchu, z ‘korelacji’ 50 pełnych wektorów DFT, określamy „spójność powtórzeń”, i usuwamy ze zbioru każdego ruchu $k=3$ do 5, najbardziej odbiegających powtórzeń ruchu. Robimy to tak. W każdej klasie wykonujemy analizę korelacji pomiędzy każdą parą wektorów ($\bar{f}s^{i,r}, \bar{f}s^{i,s}$), tj. obliczamy wartości $\sigma_{r,s}^i = \text{corr}(\bar{f}s^{i,r}, \bar{f}s^{i,s})$, dla $r=1, \dots, R$, $s=1, \dots, R$, tworząc macierz korelacji:

$$MK_i = \begin{bmatrix} \sigma_{1,1}^i & \sigma_{1,2}^i & \dots & \dots & \sigma_{1,R}^i \\ \sigma_{2,1}^i & \sigma_{2,2}^i & & & \sigma_{2,R}^i \\ \dots & \dots & \dots & & \dots \\ \dots & \dots & \dots & \dots & \dots \\ \sigma_{R,1}^i & \sigma_{R,2}^i & \dots & \dots & \sigma_{R,R}^i \end{bmatrix} \quad (4)$$

Następnie obliczamy sumaryczną korelację $G\sigma_r$ każdego wektora $\bar{f}s^{i,r}$, dla $r=1,\dots,R$, z pozostałymi wektorami, wykonując sumowanie w każdym wierszu macierzy:

$$G\sigma_r^i = \sum_{s=1}^R \sigma_{r,s}^i \quad (5)$$

Niech $D_i = \{d^{i,r} \mid r = 1,\dots,50\}$, $i=1,\dots,9$, oznacza zbiór wektorów reprezentujących powtórzenia ruchu typu i . W dalszej części analizy można odrzucić $k' = 2-3$, wektorów czasowych ze zbioru $D_i = \{d^{i,r}\}$, dla których wartości $G\sigma_r^i$ mają najmniejsze wartości. Liczba odrzucanych wektorów jest przyjmowana w sposób arbitralny. Jeśli $k'=0$, to nie są odrzucane żadne wektory. Wówczas $R=50$ wektorów ze zbioru $D_i = \{d^{i,r}\}$ jest wykorzystywanych do dalszej analizy.



Rys. 6. Ilustracja korelacji dla 50-ciu wektorów (piksele brązowe reprezentują wysoką korelację – na przekątnej wynoszącą 1, piksele niebieskie – niską)

6. WTÓRNA BAZA DANYCH (STFT)

Dla każdego zarejestrowanego sygnału (dla 9 ruchów x (50-n) powtórzeń), dla każdego kanału, wyznaczamy spektrogram za pomocą transformaty STFT.

Niech $D_i^* = \{d^{i,r} \mid r = 1, \dots, R^*\}$, gdzie $d^{i,r} = \langle w^{i,r} \rangle = \bar{w}_1^{i,r}, \bar{w}_2^{i,r}, \dots, \bar{w}_8^{i,r}$ oznacza zbiór wektorów czasowych, które pozostały po odrzuceniu wektorów najmniej skorelowanych ($R^* = (R - k')$ oznacza liczbę elementów zbioru D_i^*).

Oddzielnie dla każdego wektora czasowego $\bar{w}_k^{i,r}$, z kanału $k=1,2,\dots,8$, wyznaczamy krótkoczasową, dyskretną transformatę Fouriera (STFT), obliczając macierz dwuwymiarową $ZT_k^{i,r} = P_4(\bar{w}_k^{i,r})$ liczb zespolonych, która reprezentuje spektrogram składowych zespolonych energii sygnału w dziedzinie częstotliwości i czasu. Parametry transformaty dobieramy w taki sposób, aby długość okna czasowego była potęgą liczby 2 i równa wartości parametru $nfft = 128$. Długość obszaru nakładania (oversampling) przyjęto $n = 30$. Dla tych parametrów, w wyniku operacji $P_4(\bar{w}_k^{i,r})$ dla sygnału z pojedynczego kanału $k=1,2,\dots,8$, otrzymujemy dwuwymiarową macierz $ZT_k^{i,r}$. Dla każdego elementu tej macierzy wyznaczamy moduł liczby zespolonej i otrzymujemy macierz $SP_k^{i,r} = |ZT_k^{i,r}|$, reprezentującą spektrogram rozkładu energii w dziedzinie czasu i częstotliwości w jednym kanale, w której liczba wierszy $nw=65$ określa liczbę przedziałów częstotliwościowych, a kolumn $nk=20$ - liczbę przedziałów czasowych, w których wyznaczone są wartości energii sygnału opisanego za pomocą wektora $\bar{w}_k^{i,r}$.

$$SP_k^{i,r} = \begin{bmatrix} s_{k,1,1}^{i,r} & s_{k,1,2}^{i,r} & \dots & \dots & s_{k,1,20}^{i,r} \\ s_{k,2,1}^{i,r} & s_{k,2,2}^{i,r} & & & s_{k,2,20}^{i,r} \\ \dots & \dots & \dots & & \dots \\ \dots & \dots & \dots & \dots & \dots \\ s_{k,65,1}^{i,r} & s_{k,65,2}^{i,r} & \dots & \dots & s_{k,65,20}^{i,r} \end{bmatrix} \quad (6)$$

Wartości zapisane w macierzy $SP_k^{i,r}$ mogą być zobrazowane na płaszczyźnie w postaci spektrogramu 2D. Wtedy wartości z macierzy są odróżniane za pomocą odpowiednio dobranych kolorów (P_4).

Innym sposobem zobrazowania macierzy $SP_k^{i,r}$ jest wykres przestrzenny, tzw. spektrogram 3D, w którym poszczególne wartości macierzy są reprezentowane przez wysokości słupków (P_{4a}).

Ostatnim sposobem zobrazowania $SP_k^{i,r}$ jest spektrogram słupkowy, który powstaje w wyniku przekształcenia macierzy $SP_k^{i,r}$ do postaci macierzy zredukowanej $ZSP_k^{i,r}$, ($znw=20$ wierszy i $znk=20$ kolumn). W tej macierzy liczba wierszy odpowiada zredukowanej liczbie punktów częstotliwościowych, natomiast liczba kolumn odpowiada punktom czasowym spektrogramu (P_{4b}).

Redukcja liczby punktów częstotliwościowych spektrogramu $SP_k^{i,r}$ z wartości $nw = 65$ do wartości $znw = 20$, obejmuje dwa etapy:

- **1szy** etap polega na odrzuceniu 5 punktów częstotliwościowych o najwyższych

wartościach częstotliwości, odpowiadających 5 ostatnim wierszom macierzy $SP_k^{i,r}$, tj. wierszy $SP_k^{i,r}[61]$, $SP_k^{i,r}[62]$, $SP_k^{i,r}[63]$, $SP_k^{i,r}[64]$, $SP_k^{i,r}[65]$,

- **2gi** etap sprowadza się do zastąpienia w każdej kolumnie o numerze $k=1,...,20$, macierzy $SP_k^{i,r}$, każdego trzech kolejnych punktów częstotliwościowych ich wartością średnią, tj. do wykonania operacji:

$$ZSP_k^{i,r}[l][n] = zs_{k,l,n}^{i,r} = \frac{1}{3}(SP_k^{i,r}[a+1][n] + SP_k^{i,r}[a+2][n] + SP_k^{i,r}[a+3][n]), \quad (7)$$

gdzie: $l=1,...,20$; $n=1,...,20$; $a=3 \cdot (l-1)$;

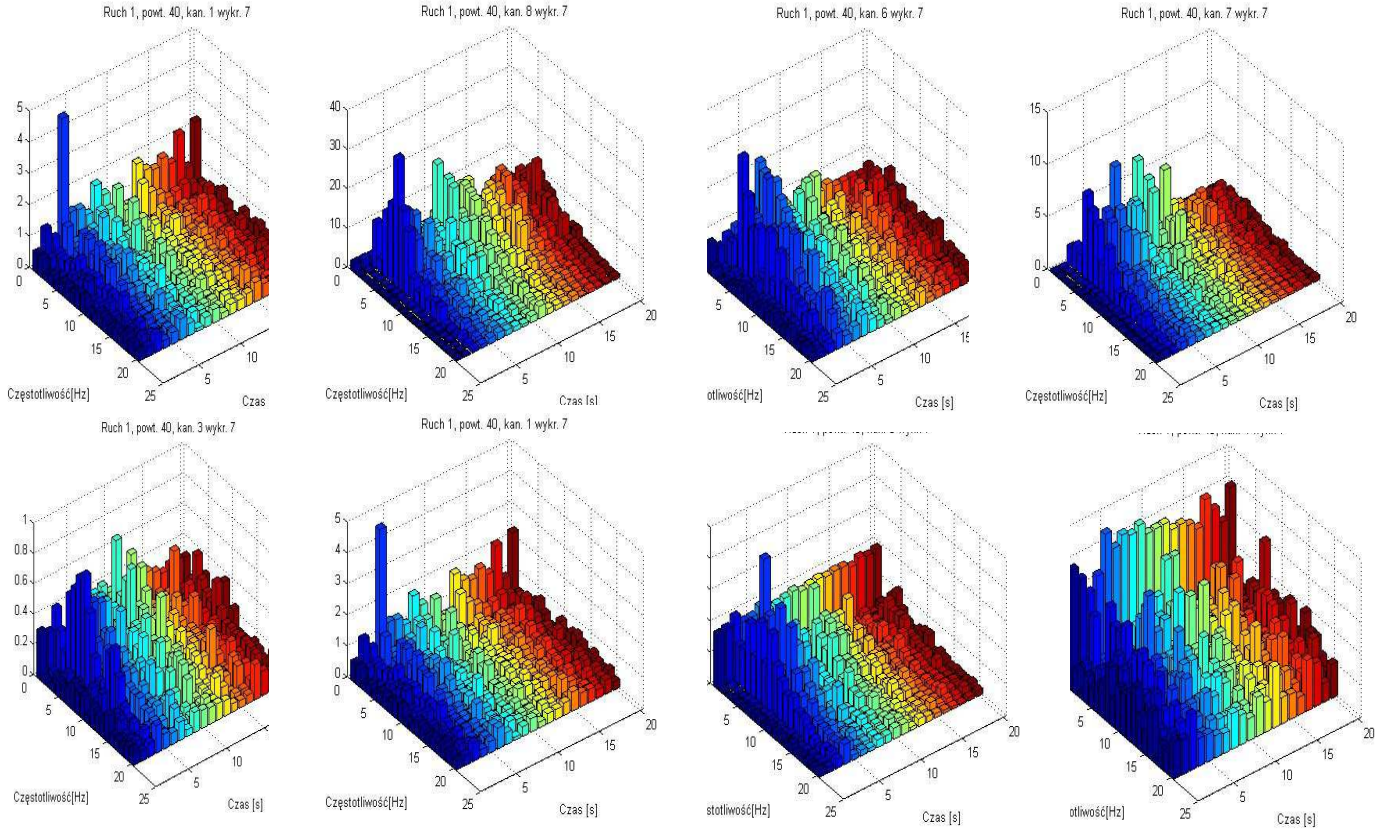
Otrzymujemy macierz $ZSP_k^{i,r}$ ($i=1,...,9$; $k=1,...,8$; $r=1,...,R^*$) o wymiarach $znw=20$ oraz $znk=20$, reprezentującą spektrogram słupkowy 3D. W macierzy tej każda kolumna odpowiada kolejnym punktom czasowym spektrogramu, natomiast wartości w kolejnych wierszach danej kolumny reprezentują uśrednione wartości energii, sumowane po 3 kolejnych punktach częstotliwościowych.

$$ZSP_k^{i,r} = \begin{bmatrix} zs_{k,1,1}^{i,r} & zs_{k,1,2}^{i,r} & \dots & \dots & zs_{k,1,20}^{i,r} \\ zs_{k,2,1}^{i,r} & zs_{k,2,2}^{i,r} & & & zs_{k,2,20}^{i,r} \\ \dots & \dots & \dots & & \dots \\ \dots & \dots & \dots & \dots & \dots \\ zs_{k,20,1}^{i,r} & zs_{k,20,2}^{i,r} & \dots & \dots & zs_{k,20,20}^{i,r} \end{bmatrix} \quad (8)$$

Kolumny tej macierzy zostaną wykorzystane do utworzenia wektora cech $\bar{h}_k^{i,r}$, reprezentującego r -te powtórzenie ruchu typu i dla kanału $k=1,2,...,8$. Wektor cech sygnału w kanale k (tzw. **wektor_spektrogramowy**) ma $\alpha = 400$ współrzędnych i powstaje w wyniku konkatencji kolumn macierzy, tj. zestawienia wartości energii w danym punkcie czasu w kolejnych punktach częstotliwościowych.

$$\begin{aligned} \bar{h}_k^{i,r} &= [zs_{k,1,1}^{i,r}, zs_{k,2,1}^{i,r}, \dots, zs_{k,20,1}^{i,r}, zs_{k,1,2}^{i,r}, zs_{k,2,2}^{i,r}, \dots, zs_{k,20,2}^{i,r}, \dots, zs_{k,1,20}^{i,r}, zs_{k,2,20}^{i,r}, \dots, zs_{k,20,20}^{i,r}] = \\ &= [h_{k,1}^{i,r}, h_{k,2}^{i,r}, \dots, h_{k,400}^{i,r}] \end{aligned} \quad (9)$$

gdzie $i=1,...,9$ jest numerem ruchu, natomiast $r=1,...,R^*$, jest numerem powtórzenia ruchu (po wcześniejszym odrzuceniu najgorszych powtórzeń), $k=1,2,...,8$, jest numerem kanału.



Rys. 7. Przykładowe spektrogramy słupkowe 3D dla 8-miu kanałów.

6.1. Pełny wektor cech

Wartości amplitud pojedynczego spektrogramu, dla jednego kanału k , dla danego powtórzenia r ruchu i , układamy w wektor $\bar{h}_k^{i,r}$ (9), w następujący sposób: kolejne wartości wg rosnących częstotliwości w pierwszej chwili czasu, potem podobnie dla kolejnych (rosnąco) chwil czasu.

Pełny wektor cech STFT, reprezentujący 8 kanałów, (dla r -tego powtórzenia ruchu i), tworzymy konkatenując wektory $\bar{h}_k^{i,r}$ w jeden wektor:

$$h^{i,r} = \bar{h}_1^{i,r} \oplus \bar{h}_2^{i,r} \oplus \dots \oplus \bar{h}_8^{i,r} = [h_1^{i,r}, \dots, h_j^{i,r}, \dots, h_{3200}^{i,r}], \quad (10)$$

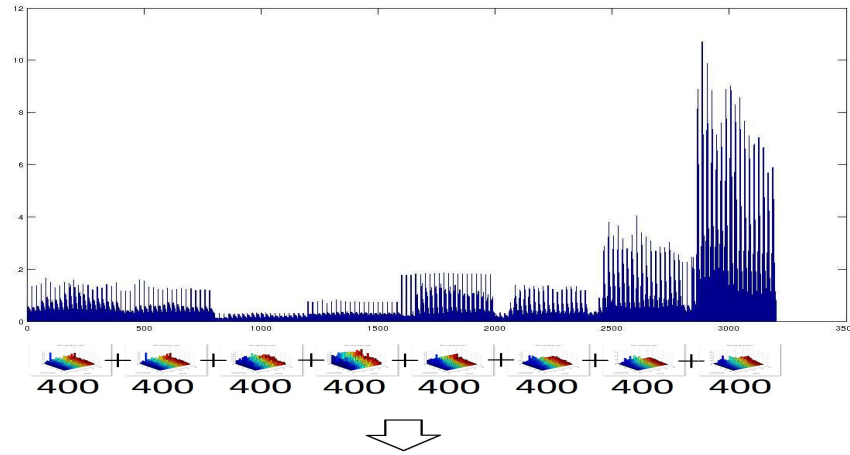
gdzie: j - numer współrzędnej wektora ($j=1,2,\dots,3200$).

Łącząc wektory $h^{i,r}$ dla wszystkich $r = 1, \dots, R$, powtórzeń danego typu ruchu oraz wszystkich typów ruchów $i = 1, \dots, 9$, otrzymujemy tzw. macierz spektrogramową H :

$$H = [H^1, H^2, \dots, H^9]^T, \quad (11)$$

gdzie:

$$H^i = [h^{i,1}, h^{i,2}, \dots, h^{i,R}]^T \quad (12)$$



Wektor (3200 próbek) - 1 powtórzenie

Rys. 8. Ilustracja tworzenia pełnego wektora STFT (dla r -tego powtórzenia ruchu typu i). W górnej części widać „rozłożone” spektrogramy dla kolejnych kanałów; w dolnej ich konkatencję w jeden wektor cech.

6.2. Spójność wartości poszczególnych współrzędnych w klasie

Analizujemy każdą j -tą współrzędną wektora cech $h_j^{i,r}$ (po wszystkich powtórzeniach r , w klasie i)

i określamy jej średnią: $\mu_j^i = \frac{1}{R^*} \sum_{r=1}^{R^*} h_j^{i,r}$, oraz odchylenie: $\sigma_j^i = \sqrt{\frac{1}{R^*} \sum_{r=1}^{R^*} (h_j^{i,r} - \mu_j^i)^2}$, w klasie,


gdzie: R^* liczba powtórzeń w klasie po odrzuceniu powtórzeń o niskiej korelacji. Normalizujemy odchylenie (n-odchylenie) dzieląc je przez średnią:

$$n\sigma_j^i = \sigma_j^i / \mu_j^i \quad (13)$$

Powtarzamy to dla wszystkich współrzędnych $h_j^{i,r}$ ($j=1,2,\dots,3200$), wektorów $h^{i,r}$ w klasie oraz po wszystkich klasach ($i=1,\dots,9$).

6.3. Analiza ‘złych’ współrzędnych w klasie

Tworzymy ranking n-odchyłeń współrzędnych wektora cech. Przyjmujemy **próg_σ** (wspólny dla wszystkich współrzędnych wektora cech). Sprawdzamy, dla których współrzędnych i , n-odchylenia przekraczają próg, $i : \sigma_i > \text{próg}_\sigma$, i ile to współrzędnych. Zaznaczamy je jako ‘złe’, wskazane do odrzucenia.



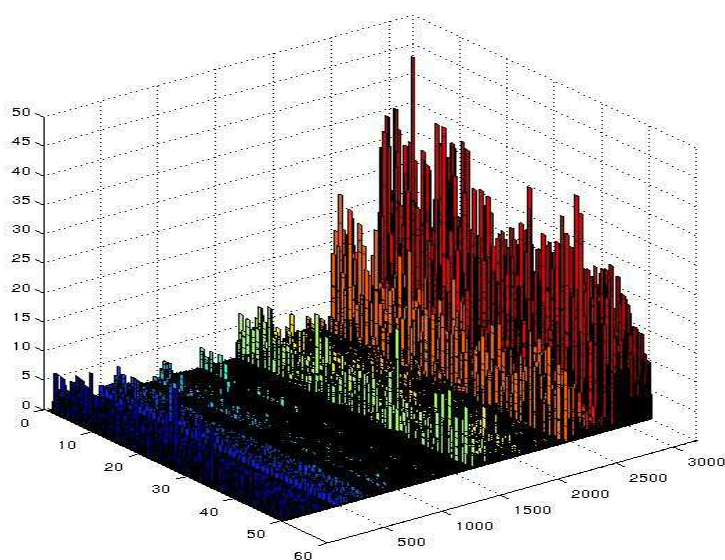
Rys. 9. Rozkład wartości znormalizowanych n-odchyłeń w klasie (jak widać można przyjąć „odcięcie” około 200 - 300 ostatnich elementów – z całej liczby 3200).

6.4. Usuwanie współrzędnych i klas - analiza zbiorcza

Porównujemy wyniki „wewnątrz klasowe” dla różnych klas. Tworzymy macierz wartości σ'_i ‘złych’ współrzędnych w poszczególnych klasach (wiersze odpowiadają kolejnym_klasom / kolumny kolejnym współrzędnym_wektora_cech / komórki przyjmują wartości: 0 – ‘dobra’ współrzędna lub σ'_i – ‘zła’ współrzędna). Dodatkowy, dolny wiersz macierzy zawiera Σ'_w wartości σ' w kolumnie oraz Σ_w - liczbę powtórzeń ruchu dla których dana współrzędna wektora ‘jest zła’. Dodatkowa kolumna (z prawej strony) zawiera Σ'_R - sumę wartości σ' w wierszu oraz Σ_R - liczbę ‘złych’ współrzędnych w danej klasie ruchu.

Ustalamy progi $\Sigma'_w\max$, $\Sigma_w\max$ i $\Sigma'_R\max$, $\Sigma_R\max$ których przekroczenie sugeruje usunięcie odpowiednio danej współrzędnej i danego ruchu z dalszych badań.

Ruchy usuwamy w ostateczności. Przed taką decyzją można podjąć próbę modyfikacji ruchu tak, aby zwiększyć różnicę aktywności mięśni w ruchach podobnych.



Rys. 10. Przykładowy obraz macierzy odchyłeń poszczególnych współrzędnych 50 wektorów cech w pojedynczej klasie, po uwzględnieniu „maski” „dobrych” (0) i „złych” ($\sigma' \neq 0$) współrzędnych.

7. ZALEŻNOŚCI „POMIĘDZY” PARAMI KLAS

7.1. Średni reprezentant w klasie

Dla każdej klasy ruchu, wyznaczamy „średniego reprezentanta ruchu” (s-reprezentanta) – wektor ulokowany w ‘środku’ grupy wektorów danej klasy ruchu. Dla k -tej klasy wektor ma postać:

$$\mu^k = [\mu_1^k, \mu_2^k, \dots, \mu_n^k], \quad (n=3200) \quad (14)$$

7.2. Różnice współrzędnych pomiędzy parami klas

Dla każdej współrzędnej, każdej pary „średnich reprezentantów” (dla każdej pary klas 1-2, 1-3, ..., 8-9), wyznaczamy miarę dyskryminacji na dwa sposoby - jako:

a) „znormalizowaną różnicę -1”: $|k-l|_{(1)} \rightarrow \Delta(1)_j^{k-l} = \frac{|\mu_j^k - \mu_j^l|}{\mu_j^k + \mu_j^l}, \quad (15)$

b) „znormalizowaną różnicę -2”: $|k-l|_{(2)} \rightarrow \Delta(2)_j^{k-l} = \frac{|\mu_j^k - \mu_j^l|}{\delta_j^k \delta_j^l}, \quad (16)$

Dodatkowo, dla każdej współrzędnej, dla każdej pary wektorów $h^{i,r}$ (z klas 1-2, 1-3, ..., 8-9), wyznaczamy miarę dyskryminacji jako:

c) „znormalizowaną wartość min”: $|k-l|_{(3)} \rightarrow \Delta(3)_j^{k-l} = \min_{(k,r),(l,r)} |h_j^{k,r} - h_j^{l,r}|, \quad (17)$

gdzie: $j=1,2,\dots,3200$.

Podane miary dyskryminacji zostaną wykorzystane do selekcji współrzędnych wektora cech.

7.3. Macierze dyskryminacji $M\Delta$

Tworzymy „macierze dyskryminacji” po wszystkich współrzędnych wektora (dla wariantu $\Delta(3)$, także po wszystkich powtórzeniach r) i po wszystkich parach klas: - kolejne wiersze odpowiadają: kolejnym_param_klas_ $(k-l)$, - kolejne kolumny: kolejnym_współrzędnym_wektora, - komórki: wartościom miary dyskryminacji.

Do macierzy wprowadzamy dodatkową kolumnę (z prawej strony), która zawiera sumy komórek każdego wiersza.

$$M\Delta(d) = \begin{bmatrix} \Delta(d)_1^{1-2} & \Delta(d)_2^{1-2} & \dots & \Delta(d)_{3200}^{1-2} & \Delta(d)^{1-2} = \sum_{a=1}^{3200} \Delta(d)_a^{1-2} \\ \Delta(d)_1^{1-3} & \Delta(d)_2^{1-3} & \dots & \Delta(d)_{3200}^{1-3} & \Delta(d)^{1-3} = \sum_{a=1}^{3200} \Delta(d)_a^{1-3} \\ \dots & \dots & \dots & \dots & \dots \\ \Delta(d)_1^{k-l} & \Delta(d)_2^{k-l} & \dots & \Delta(d)_{3200}^{k-l} & \Delta(d)^{k-l} = \sum_{a=1}^{3200} \Delta(d)_a^{k-l} \\ \Delta(d)_1^{8-9} & \Delta(d)_2^{8-9} & \dots & \Delta(d)_{3200}^{8-9} & \Delta(d)^{8-9} = \sum_{a=1}^{3200} \Delta(d)_a^{8-9} \end{bmatrix} \quad (18)$$

Porządkujemy macierze po wartościach ostatniej kolumny (najniższe wartości wskazują na najgorzej rozróżniane pary). Porządkujemy wiersze macierzy (odrębny ranking dla każdej pary) po

wartościach komórek wiersza (najwyższe wartości wskazują najlepsze współrzędne wektora cech ze względu na rozróżnianie danej pary klas).

Dla każdej pary klas (odrębnie) wybieramy najmniejszą liczbę współrzędnych, która zapewnia określony poziom rozróżnienia klas tej pary (których suma jest bliska ale nie przekracza zadanego progu, np. 2000). Tworzymy zbiory numerów współrzędnych wybranych dla wszystkich par klas. Sumujemy logicznie te zbiory – uzyskując zestaw (pojedynczych numerów) najlepszych współrzędnych wektora cech.

Tablica 2. Tabela wartości „znormalizowanej różnicy-1” pomiędzy parami klas posortowanymi po wierszach wg „Σ wartości w wierszu” oraz po kolumnach wg najwyższych wartości w wierszu (indywidualnym).

Nazwa pary	1. najlepsza	2. najlepsza	3. najlepsza	4. najlepsza	...	2. najgorsza	1. najgorsza	Σ w wierszu	Ilość próbek, których Σ ≤ 2000
2-3	8,86	8,85	8,53	8,29	...	0,08	0,07	3087,14	968
	2886	2885	3006	3007		803	1223		
1-3	9,17	9,1	8,78	8,54	...	0,08	0,08	3261,15	853
	2886	2885	3006	3007		1123	1183		
1-2	10,92	10,44	10,09	9,37	...	0,1	0,1	3488,51	713
	2885	2886	2905	2906		838	1120		
6-9	9,77	9,47	8,95	8,62	...	0,11	0,1	4268,29	559
	2865	2866	3025	3026		802	2403		
5-9	9,6	9,28	8,72	8,54	...	0,14	0,13	4333,51	564
	2865	2866	3025	2886		2019	920		
4-9	9,6	9,27	8,64	8,37	...	0,11	0,1	4350,22	501
	2865	2866	3025	2885		1120	823		
2-9	11,04	10,62	10,52	10,16	...	0,07	0,05	4488,93	455
	1646	1647	1666	1645		1123	2023		
4-5	17,78	17,73	15,86	15,85	...	0,13	0,12	6961,7	230
	2886	2885	2906	2884		979	859		
3-4	19,93	18,68	18,01	17,19	...	0,09	0,09	7056,92	188
	2946	2561	2945	2865		1503	804		
... ..									
2-8	22,97	22,97	20,43	20,36	...	0,08	0,07	7468,32	177
	148	147	167	146		1203	1603		
3-8	20,52	19,89	19,09	18,91	...	0,09	0,09	7520,58	192
	261	3006	186	148		2022	1123		
1-6	25,05	23,23	22,41	21,73	...	0,11	0,07	8157,45	155
	3026	3006	2865	3027		860	1603		
1-5	20,34	17,65	17,42	15,85	...	0,12	0,12	8266,9	174
	2601	2885	2886	2884		2040	1243		
2-5	23,87	18,17	18,04	16,68	...	0,12	0,12	8583,05	194
	2601	2885	2886	2865		2019	2040		
2-6	26,02	23,91	23,75	22,64	...	0,11	0,07	8740,73	139
	3026	3006	2865	3027		2040	2003		
3-5	21,66	18,54	18,31	17,29	...	0,13	0,12	9204,52	167
	2601	2885	2886	2865		938	2039		
3-6	26,36	24,6	24,04	23,09	...	0,12	0,1	9388,31	133
	3026	2865	3006	3027		938	2403		

Z tabeli 2, indywidualnie dla każdej pary klas, wybieramy pierwsze n komórek, których suma wartości „znormalizowanych różnic-1” (ostatnia kol. tabeli) nie przekracza wartości 2000. Sumujemy logicznie numery współrzędnych odpowiadające wybranym komórkom, i uzyskujemy zestaw 1472 współrzędnych. Numery pierwszych 25 współrzędnych z zestawu przedstawia Tab. 3.

Tabela 3. Ilustracja najlepszych współrzędnych wektora (pierwsze 25 najlepszych)

Ranking najlepszych wsp. wektora	Nr współrzędnej wektora	Liczba par, w których wybrano daną współrzędną
1	2865	36
2	2866	36
3	2867	36
4	2985	36
5	2986	36
6	2987	36
7	3005	36
8	3006	36
9	3007	36
10	3008	36
11	3024	36
12	3025	36
13	3026	36
14	3027	36
15	3028	36
16	3029	36
17	3045	36
18	3046	36
19	3047	36
20	3048	36
21	3065	36
22	3066	36
23	3067	36
24	2864	35
25	2845	34

Jak widać pierwsze 23 najlepszych współrzędnych zostało wybranych niezależnie w każdej z 36 par klas.

8. EKSPERYMENT KLASYFIKACJI

Jak zostało przedstawione wcześniej, w prezentowanym podejściu eksperymentalnym, ocenę efektywności metod analizy stanowi porównanie końcowych błędów rozpoznawania wektorów cech przygotowanych różnymi metodami. W przeprowadzonych badaniach do rozpoznawania zastosowano algorytm k -najbliższych sąsiadów (k -NN).

Algorytm k -NN jest przykładem klasyfikatora, którego zasada działania opiera się na badaniu własności obiektów znanych (uczących, treningowych), pozostających w najbliższym sąsiedztwie z obiektami nowymi (testowymi) w sensie ustalonej miary odległości. W szczególności, dla wybranego wektora cech X , należącego do zbioru testowego, poszukiwany jest zbiór NN (tzw. zbiór sąsiadów) złożony z k wektorów, należących do zbioru uczącego, które są najbliższe wektora badanego według ustalonej metryki. Wśród wektorów należących do zbioru najbliższych sąsiadów NN przeprowadzane jest zliczanie liczności klas. Wektor X jest przypisywany do klasy, która jest reprezentowana przez największą liczbę wektorów ze zbioru NN (w przypadku równych liczności klas wymagane jest dodatkowe kryterium).

Do najczęściej wykorzystywanych miar odległości między wektorami cech należą metryka euklidesowa, metryka miejska, i inne [1],[5]. Poniżej pokazano przykładowe metryki (19), umożliwiające wyznaczanie odległości pomiędzy wektorami cech $X=(X_1,\dots,X_m)$ oraz $Y=(Y_1,\dots,Y_m)$.

$$\rho_1(X,Y) = \sqrt{\sum_{i=1}^m (X_i - Y_i)^2} \quad - \quad \text{metryka euklidesowa} \quad (19)$$

$$\rho_2(X,Y) = \sum_{i=1}^m |X_i - Y_i| \quad - \quad \text{metryka miejska}$$

W podstawowej wersji algorytmu k -NN wszystkie współrzędne (wymiarzy) wektorów cech są traktowane jednakowo. Istnieje zmodyfikowana wersja algorytmu [x], w której wprowadzono dodatkowe wagi współrzędnych, związane z wymiarami, uwzględniane we wzorze na metrykę odległości w postaci wagi w_i (20).

$$\rho_3(X,Y) = \sqrt{\sum_{i=1}^m w_i (X_i - Y_i)^2} \quad - \quad \text{metryka euklidesowa z wagą} \quad (20)$$

Algorytm zaimplementowano z wykorzystaniem standardowej funkcji `knnclassify(sample)`, w wyniku działania której otrzymujemy informacje o numerze klasy, do której został przypisany każdy wektor testowy.

8.1. Klasyfikacja wektorów cech uzyskanych metodą selekcji naturalnej

Dla oceny połączenia algorytmu selekcji naturalnej oraz klasyfikatora k -NN, przeprowadzono eksperyment, polegający na wyznaczeniu błędu klasyfikacji wektorów cech (10), z 9-ciu klas ruchów zapisanych w macierzy spektrogramowej (11). W tym celu z każdego zbioru H^i (12) (gdzie $i=1,\dots,9$; $r=1,\dots,R=50$) wybrano 30 kolejnych wektorów cech do zbioru uczącego, natomiast następne 20 wektorów do zbioru testowego. W sumie pełny zbiór uczący zawiera 270 (9×30) wektorów cech, natomiast zbiór testowy zawiera 180 (9×20) wektorów. Testy przeprowadzono dla parametru jednego sąsiada 1-NN ($k=1$) oraz metryki euklidesowej (19).

Szczegółowe wyniki klasyfikacji zostały podane w tabelach zawierających, dla każdego wektora testowego, numer klasy i powtórzenia wektora uczącego, który jest najbliższy do badanego. Wyniki ilościowe zostały podane w tabelach prawdy.

8.1.1. Wyniki klasyfikacji danych bez selekcji

Na początku przeprowadzono klasyfikację „surowych” wektorów cech, bez selekcji współrzędnych w oparciu o przedstawiony algorytm selekcji naturalnej.

Tabela 4. Wyniki testów dla wszystkich klas – dane bez selekcji

Nr rozp. klasy nr testu	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Test 1	1028	2028	3018	4018	5024	6024	7027	8025	9024
Test 2	1028	2028	3023	4018	5020	6018	7014	8026	9007
Test 3	1012	2027	3010	4029	5024	6022	7025	8030	9028
Test 4	1028	2014	3018	4028	2008	6018	7025	8021	9024
Test 5	2011	2014	3022	4003	5024	6007	7028	8024	9020
Test 6	2022	2026	3011	4024	5027	6016	7014	8026	9028
Test 7	1028	2010	3016	4029	5022	6018	7027	8026	9028
Test 8	2022	2010	3022	4029	5022	5023	7017	8028	9017
Test 9	1012	2014	3022	1012	5021	6010	7027	8030	9029
Test 10	1012	2014	2021	4029	5029	6010	7027	8026	9024
Test 11	1020	2010	3023	4029	5024	6025	3010	8021	9020
Test 12	1028	2018	2021	4012	5024	6012	7005	8025	9028
Test 13	1012	2014	3016	4024	5024	2001	7028	8026	9028
Test 14	1012	2014	2021	4017	5024	6024	7014	8025	9017
Test 15	1028	2024	3018	4017	5024	6010	7030	8027	9017
Test 16	1023	2025	3023	4022	5024	6018	7025	8025	9024
Test 17	1012	2018	3011	4022	5029	6008	7025	8025	9028
Test 18	1028	2018	3011	4022	5024	6026	7029	8030	9028
Test 19	1028	2014	3022	4029	5024	6016	3024	8025	9024
Test 20	1028	2014	3021	4012	5027	6017	7025	8021	9020
Suma źle rozp.	3	0	3	1	1	2	2	0	0

Tabela 4 pokazuje szczegółowe wyniki dla kolejnych wektorów testowych (Test 1, Test 2, ..., Test 20). Każdy wynik podawany jest w formacie A0B, gdzie A – numer klasy, do której została zakwalifikowana określona próbka testowa, 0 – przerwa, B – numer próbki (powtórzenia ruchu) z klasy A, która jest najbliższej próbki testowej (zgodnie z algorytmem k-NN). W szczególności, pierwsza kolumna w tabeli 5 zawiera wyniki klasyfikacji dla wszystkich 20 testowych wektorów cech (próbek testowych), należących do klasy 1, a pozostałe kolumny zawierają wyniki klasyfikacji dla próbek testowych, które należą do kolejnych klas. Na przykład, dla danej z komórki tabeli (Test 1, Klasa 1) zapis 1028 oznacza, że pierwsza próbka (Test 1) ze zbioru testowego klasy 1 znajduje się najbliższej próbki 28, należącej do klasy 1, tj. została ona prawidłowo zakwalifikowana do klasy 1. Z kolei dana 2011, znajdująca się w komórce (Test 5, Klasa 1) tabeli, oznacza, że próbka Test 5 ze zbioru testowego klasy 1 znajduje się najbliższej próbki 11, należącej do klasy 2, tj. została ona błędnie zakwalifikowana do klasy 2. W ostatnim wierszu tabeli 2 podawane są liczby błędnie sklasyfikowanych próbek.

8.1.2. Klasyfikacja danych dobieranych w oparciu o metodę selekcji „znormalizowana różnica -1”

Kolejny test polegał na zbadaniu efektywności procesu klasyfikacji po redukcji wymiaru wektorów cech z wykorzystaniem metody selekcji naturalnej opisanej w punkcie 5. W ramach przeprowadzonych badań zastosowano mechanizm selekcji cech oparty o analizę różnic między klasami (ranking między-klasowy), który opisano w punkcie 5.3. W metodzie tej istotne znaczenie ma kryterium sumy najlepszych różnic między klasami, którego górne ograniczenie zostało zdefiniowane za pomocą parametru Σ . Na podstawie analizy wartości tego parametru przyjęto ograniczenia $\Sigma = 2000$ oraz $\Sigma = 3000$, dla których przeprowadzono selekcję cech zgodnie z algorytmem opisanym w [10].

W tabeli 7 przedstawiono szczegółowe wyniki klasyfikacji, natomiast w tabeli 8 wyniki ilościowe (tabela prawdy) dla wartości parametru $\Sigma = 2000$ i z uwzględnieniem wszystkich klas. Dla tej wartości parametru sum wymiar wektorów cech został zredukowany do wartości 1472.

Tabela 7. Wyniki testów dla wszystkich klas – dane selekcyjonowane ($\Sigma = 2000$)

Nr rozp. klasy nr testu	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Test 1	1028	2022	3018	4018	5023	6010	7027	8027	9028
Test 2	1025	2028	3023	4018	5020	6018	7014	8026	9028
Test 3	1028	2030	3008	4029	5024	6022	7025	8030	9028
Test 4	1025	2019	2022	4018	2008	6018	7025	8021	9024
Test 5	2011	2014	3022	4003	5024	6007	7005	8024	9020
Test 6	2022	3022	3010	4024	5023	6025	7014	8026	9005
Test 7	1028	2010	3016	4029	5024	6018	7015	8026	9028
Test 8	2008	2010	3022	4029	5023	5023	7017	8026	9017
Test 9	1012	2014	3026	4029	2014	6025	7026	8023	9028
Test 10	1012	2014	2021	4029	5029	6010	7027	8026	9024
Test 11	1020	2010	3022	4018	5024	6010	3010	8021	9020
Test 12	1028	2018	3018	4012	2008	6018	7005	8025	9028
Test 13	1028	2026	3016	4029	5022	2001	7003	8026	9028
Test 14	1025	2014	2021	4029	5020	6024	7023	8027	9017
Test 15	1023	2024	3016	4017	5023	6010	7030	8021	9017
Test 16	1023	2024	3023	4022	5023	6018	7025	8025	9025
Test 17	1012	2019	2010	4020	5029	6008	7025	8025	9028
Test 18	1028	2018	3011	4018	5026	6025	7029	8030	9020
Test 19	1028	2014	3022	4029	5024	6016	7017	8025	9026
Test 20	1004	2014	3017	4012	5020	5013	7025	8027	9020
Suma źle rozp.	3	1	4	0	3	3	1	0	0

Tabela 8. Tabela prawdy dla wszystkich klas – dane selekcjonowane ($\Sigma = 2000$)

Wynik klasyfikacji Nr klasy rozpoznawanej	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Klasa 1	17	3	0	0	0	0	0	0	0
Klasa 2	0	19	1	0	0	0	0	0	0
Klasa 3	0	4	16	0	0	0	0	0	0
Klasa 4	0	0	0	20	0	0	0	0	0
Klasa 5	0	3	0	0	17	0	0	0	0
Klasa 6	0	1	0	0	2	17	0	0	0
Klasa 7	0	0	1	0	0	0	19	0	0
Klasa 8	0	0	0	0	0	0	0	20	0
Klasa 9	0	0	0	0	0	0	0	0	20

Z kolei w tabeli 9 przedstawiono szczegółowy przebieg klasyfikacji dla przypadku, gdy wartość parametru $\Sigma = 3000$, natomiast tabela 10 stanowi tabelę prawdy. Dla tej wartości parametru sum wymiar wektorów cech został zredukowany do wartości 2950.

Tabela 9. Wyniki testów dla wszystkich klas – dane selekcjonowane ($\Sigma = 3000$)

Nr rozp. klasy nr testu	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Test 1	1028	2022	3023	4018	5023	6024	7027	8027	9028
Test 2	1028	2028	3023	4014	5020	6018	7014	8026	9028
Test 3	1028	2030	3010	4029	5024	6022	7025	8030	9028
Test 4	1028	2019	3014	4018	2008	6018	7028	8021	9024
Test 5	2022	2014	3018	4003	5024	6007	7028	8024	9020
Test 6	1028	2026	3010	4024	5020	6025	7014	8026	9029
Test 7	1028	2010	3016	4029	5022	6018	7024	8026	9028
Test 8	2022	2010	3022	4029	5022	5023	7017	8026	9017
Test 9	1012	2014	3026	1012	5023	6010	7017	8023	9029
Test 10	1012	2014	2021	4029	5029	6010	7027	8026	9024
Test 11	1028	2010	3022	4029	5024	6025	3010	8021	9020
Test 12	1028	2018	2021	4012	5024	6018	7005	8025	9028
Test 13	1028	2026	3016	4029	5024	2001	7028	8026	9028
Test 14	1025	2014	2021	4029	5024	6024	7014	8021	9005
Test 15	1028	2024	3010	4017	5023	6010	7030	8027	9017
Test 16	1023	2013	3023	4022	5024	6018	7025	8025	9024
Test 17	1012	2019	3010	4020	5029	6008	7025	8025	9028
Test 18	1028	2018	3011	4022	5026	6025	7029	8030	9020
Test 19	1028	2014	3022	4029	5024	6016	7030	8025	9024
Test 20	1028	2014	3019	4012	5020	5013	7025	8021	9020
Suma źle rozp.	2	0	3	1	1	3	1	0	0

Tabela 10. Tabela prawdy dla wszystkich klas – dane selekcyjonowane ($\Sigma = 3000$)

Wynik klasyfikacji Nr klasy rozpoznawanej	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Klasa 1	18	2	0	0	0	0	0	0	0
Klasa 2	0	20	0	0	0	0	0	0	0
Klasa 3	0	3	17	0	0	0	0	0	0
Klasa 4	1	0	0	19	0	0	0	0	0
Klasa 5	0	1	0	0	19	0	0	0	0
Klasa 6	0	1	0	0	2	17	0	0	0
Klasa 7	0	0	1	0	0	0	19	0	0
Klasa 8	0	0	0	0	0	0	0	20	0
Klasa 9	0	0	0	0	0	0	0	0	20

8.1.3. Klasyfikacja danych dobieranych w oparciu o metodę selekcji „znormalizowana różnica -2”

Poprzednie testy powtórzone dla metody selekcji „znormalizowana różnica -2”. Uzyskane wyniki zawierają kolejne tabele.

Tabela 11. Wszystkie klasy - dane selekcyjonowane metodą „znormalizowana różnica -2” ($\Sigma=500$)

Nr rozp. klasy nr testu	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Test 1	1026	2022	3021	4018	5023	6024	7027	8027	9017
Test 2	1025	2028	2016	4014	5020	6018	7014	8026	9028
Test 3	1028	2030	3010	4029	5024	6022	7025	8030	9028
Test 4	1025	2014	2022	4018	2008	6018	7025	8021	9024
Test 5	2011	2014	3022	4003	5024	6007	7025	8024	9020
Test 6	2022	2014	3010	4024	5020	6025	7014	8026	9005
Test 7	1028	2010	3016	4029	5024	6018	7024	8026	9028
Test 8	2022	2010	3022	4029	5024	5023	7017	8028	9017
Test 9	1028	2014	3026	4029	5020	6025	7017	8023	9028
Test 10	1012	2014	2026	4029	5029	6010	7027	8026	9024
Test 11	1028	2010	2026	4029	5024	6025	3010	8021	9020
Test 12	1028	2018	2021	4012	5020	6024	7005	8025	9028
Test 13	1028	2026	3019	4029	5024	2001	7003	8026	9028
Test 14	1025	2014	2021	4029	5024	6024	7023	8027	9005
Test 15	1028	2024	3010	4017	5029	6010	7030	8028	9017
Test 16	1023	2025	3014	4022	5020	6018	7025	8025	9024
Test 17	1012	2026	2010	4020	5029	6008	7025	8027	9028
Test 18	1028	2018	3011	4022	5026	6025	7029	8030	9020
Test 19	1028	2014	3022	4029	5024	6016	7017	8025	9026
Test 20	1028	2014	3017	4013	5020	6017	7025	8021	9020
Suma źle rozp.	3	0	7	0	1	2	1	0	0

Tabela 12: Tabela prawdy dla wszystkich klas - dane selekcyjonowane metodą „znormalizowana różnica -2” ($\Sigma=500$)

Wynik klasyfikacji Nr klasy rozpoznawanej	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Klasa 1	17	3	0	0	0	0	0	0	0
Klasa 2	0	20	0	0	0	0	0	0	0
Klasa 3	0	7	13	0	0	0	0	0	0
Klasa 4	0	0	0	20	0	0	0	0	0
Klasa 5	0	1	0	0	19	0	0	0	0
Klasa 6	0	1	0	0	1	18	0	0	0
Klasa 7	0	0	1	0	0	0	19	0	0
Klasa 8	0	0	0	0	0	0	0	20	0
Klasa 9	0	0	0	0	0	0	0	0	20

8.1.4. Klasyfikacja danych dobieranych w oparciu o metodę selekcji „znormalizowana wartość min”

Tabela 13. Wszystkie klasy - dane selekcyjonowane metodą „znormalizowana wartość min” ($\Sigma=0,8090936 - 2339$ współrzędnych)

Nr rozp. klasy nr testu	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Test 1	1026	2025	3016	4026	5023	6024	7027	8015	9020
Test 2	1028	3015	3013	4016	5028	6018	7014	8026	9007
Test 3	1012	2029	3008	4029	5024	6022	7025	8023	9028
Test 4	1025	2004	2022	4018	4008	6018	7025	8021	9005
Test 5	1020	2014	3007	4003	5007	6007	7005	8024	9020
Test 6	1028	2014	3010	1005	5023	6025	7014	8026	9028
Test 7	1012	3009	3016	4029	5021	6018	7024	8026	9028
Test 8	2008	3014	2026	4029	5023	5023	7007	8026	9017
Test 9	2008	2014	3006	1012	5028	6025	7027	8023	9028
Test 10	1012	2005	2026	4029	5029	6010	7027	8026	9017
Test 11	1025	2013	2026	4029	5027	6010	3010	8021	9020
Test 12	1027	2014	3018	4012	2008	5024	7005	8025	9024
Test 13	1028	3022	3016	4029	5017	2005	7003	8026	9017
Test 14	1025	3016	2021	4017	5011	6024	7014	8027	9005
Test 15	1026	2027	3016	4017	5023	6005	7027	8027	9017
Test 16	1005	3017	3023	4003	5028	6009	7025	8025	9005
Test 17	1012	3030	2010	4004	5024	6006	7025	8027	9028
Test 18	1010	2018	3018	4018	5020	6025	7014	8030	9020
Test 19	1028	2014	3030	4029	5024	6016	7029	8025	9028
Test 20	2024	2021	3013	4029	5021	5013	7025	8021	9021
Suma źle rozp.	3	7	6	2	2	4	1	0	0

Tabela 14: Tabela prawdy dla wszystkich klas przy danych wybranych wg kryterium „znormalizowana wartość min” i dla Σ nie przekraczającej wartości 0.8090936 (2339 współrzędnych)

[illegible]

8.2. Klasyfikacja z wykorzystaniem metody redukcji PCA

W przypadku stosowania algorytmu selekcji PCA oraz klasyfikatora k -NN, przeprowadzono eksperyment, polegający na ocenie błędu klasyfikacji wektorów cech (10), odpowiadających 9-ciu klasom ruchów i zapisanych w macierzy spektrogramowej (11). W tym celu z każdego zbioru H^i (12) (gdzie $i=1, \dots, 9$; $r=1, \dots, R=50$) wybrano losowo 10 wektorów cech do zbioru testowego (funkcja `creating_test` – listing 27), natomiast pozostałe 40 wektorów cech do zbioru uczącego (treningowego). W sumie pełny zbiór treningowy wykorzystywany przez klasyfikator k -NN zawiera 360 (9×40) wektorów, natomiast zbiór testowy zawiera 90 (9×10) wektorów. Testy przeprowadzono dla przypadku klasyfikatora z jednym, najbliższym sąsiadem 1-NN ($k=1$) oraz z użyciem metryki euklidesowej (19).

Efekty klasyfikacji zostały podane w postaci tabel prawdy, w których zawarto zestawienie ilościowe wyników klasyfikacji 10 wektorów testowych dla każdej z 9 klas ruchu, uwzględniając różne poziomy redukcji wymiaru przestrzeni cech – różne wartości parametru „dimension” w algorytmie PCA. W szczególności, tabela 15 zawiera wyniki klasyfikacji dla wartości parametru dimension=3000, tabela 16 dla wartości dimension=2000, tabela 17 –dimension=500, tabela 18 – dimension=400, tabela 19 – dimension=200, i tabela 20 – dimension=150.

Tabela 1. Tabela prawdy dla wszystkich klas – dane filtrowane PCA (dimension=3000)

Wynik klasyfikacji	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Nr klasy rozpoznawanej									
Klasa 1	10	0	0	0	0	0	0	0	0
Klasa 2	0	8	2	0	0	0	0	0	0
Klasa 3	0	1	9	0	0	0	0	0	0
Klasa 4	0	0	0	10	0	0	0	0	0
Klasa 5	0	0	0	0	10	0	0	0	0
Klasa 6	0	0	0	0	0	10	0	0	0
Klasa 7	0	0	2	0	0	0	8	0	0
Klasa 8	0	0	0	0	0	0	0	10	0
Klasa 9	0	0	0	0	0	0	0	0	10

Tabela 2. Tabela prawdy dla wszystkich klas – dane filtrowane PCA (dimension=2000)

[illegible]


Tabela 20. Tabela prawdy dla wszystkich klas – dane filtrowane PCA (dimension=150)

Wynik klasyfikacji Nr klasy rozpoznawanej	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa 5	Klasa 6	Klasa 7	Klasa 8	Klasa 9
Klasa 1	8	1	1	0	0	0	0	0	0
Klasa 2	0	10	0	0	0	0	0	0	0
Klasa 3	0	0	10	0	0	0	0	0	0
Klasa 4	0	1	0	9	0	0	0	0	0
Klasa 5	0	0	0	0	10	0	0	0	0
Klasa 6	0	0	0	0	0	10	0	0	0
Klasa 7	0	0	2	0	0	0	10	0	0
Klasa 8	0	0	0	0	0	0	0	10	0
Klasa 9	0	0	0	0	0	0	0	0	10

Na podstawie przedstawionych wyników widać, że błąd klasyfikacji z wykorzystaniem selekcji PCA jest dla wszystkich wartości parametru „dimension” prawie jednakowy. Można zauważyć, że klasyfikacja z użyciem PCA jest mniej wrażliwa na obecność klas ruchów 2, 6, 7 w porównaniu do klasyfikacji z wykorzystaniem algorytmu selekcji naturalnej, opisanego w punkcie 3.4.


9. PODSUMOWANIE

Uzyskane wyniki (tabele 5 – 16) pokazują, że cechy uzyskane w wyniku przyjętej metodologii akwizycji i analizy zarejestrowanych danych (zestaw ruchów, rozmieszczenie punktów pomiarowych, rodzaj mierzonych sygnałów, transformacja STFT oraz zastosowane metody selekcji/redukcji cech) nie zapewniają 100% rozróżnialności badanych ruchów chwytnych.



Rysunek 11. Rozkład wartości najlepszych współrzędnych, dla 50-ciu realizacji, dla „najgorszej pary” ruchów (2-3).

Na rysunkach 11 i 12 przedstawiono przykładowe rozkłady wartości najlepszych współrzędnych (numery na rysunkach), dla 50-ciu realizacji, dla najgorzej (2-3) i najlepiej (3-6) rozróżnianej pary ruchów. Widać, że te cechy nie mogą zapewnić poprawnej klasyfikacji. Wynika to zarówno ze „zbyt ambitnego” wyboru ruchów (np. precyzyjny, dwu-palcowy chwyt śrubki vs. trójpalcowy chwyt osi potencjometru), braku przy rejestracji precyzyjnego mechanizmu detekcji początku akcji ruchowej („onset”) jak i zbyt małej populacji zarejestrowanych powtórzeń (rejestrowano po 50 powtórzeń na klasę, a powinno być ponad 200).



Rysunek 12. Rozkład wartości najlepszych współrzędnych, dla 50-ciu realizacji, dla „najlepszej pary” ruchów (3-6).

Porównanie pomiarów dla różnych osób pokazuje, że wpływ wymienionych wyżej czynników występuje w istotnie różnym nasileniu. Sugeruje to, że osoby o różnych cechach psychomotorycznych (lepszego koordynacji ruchowej?), bez wstępnego treningu, dostarczają danych o różnym stopniu powtarzalności. Wskazuje to na potrzebę jakiejś formy treningu wstępnego.

Również analiza istotności cech pokazuje, że rozmieszczenie punktów pomiarowych należy zagęścić w górnej części przedramienia (bliżej łokcia).

W procesie akwizycji danych nie wykorzystano modalności MMG. Wynikało to z okresowej niesprawności systemu pomiarowego w wersji 16-to kanałowej.

Niezależnie od wymienionych czynników, możliwym rozwiązaniem zwiększającym bezpieczeństwo działania protezy wydaje się wprowadzenie klasy „0” (nic nie rób), do której będą zaliczane sygnały, których wektory cech są zbyt odległe od „obszarów klas aktywnych”.

Literatura

- [1] Duda R., Hart P. and Stork D., 'Pattern Classification', John Wiley, 2002
- [2] Jolliffe I. T., Principal Component Analysis, 2nd ed., Springer, 2002
- [3] Katsis C.D., Goletsis Y., Likas A., Fotiadis D.I., Sarmas I., A novel method for automated EMG decomposition and MUAP classification, Artificial Intelligence in Medicine, 2006.
- [4] Reaz M., Hussain M., Techniques of EMG signal analysis: detection, processing, recognition and applications, Biological Procedures Online, 8 (2006), 11 – 35
- [5] Sobczak W., Malina W., Metody selekcji i redukcji informacji, WNT, Warszawa, 1985
- [6] Wojtczak P., Amaral T., Dias O., Wolczowski A., Kurzynski M., Hand movement recognition based on biosignal analysis, Engineering Applications of Artificial Intelligence 22 (2009), 608 – 615
- [7] Wolczowski, S. Myslinski, Identifying the relation between finger motion and EMG signals for bioprosthesis control, Proc. 12th IEEE Int Conf. MMAR'06 (2006), 234 – 245
- [8] Wolczowski, M. Kurzynski, Human –machine interface in bio-prosthesis control using EMG signal classification, Expert Systems 27 (2010), 53 – 70
- [9] Wołczowski A., Witkowski J. S., Stanowisko badawcze do akwizycji biosygnaliów [dokumentacja projektu], Politechnika Wrocławska, Wrocław, 2013.
- [10] Wójcik R., Opracowanie oprogramowania do akwizycji i analizy biosygnaliów – procedury i eksperymenty praktyczne, Raport serii SPR-02/2014, wydział Elektroniki, Politechnika Wrocławska, 2014.
- [11] Xie HB, Guo T., Bai S., Dokos S., Hybrid soft computing systems for electromyographic signals analysis: a review, BioMedical Engineering, 2014